

ÉCOLE NATIONALE D'ÉCONOMIE APPLIQUÉE ET DE MANAGEMENT
Ingénieurs Statisticiens Économistes — Data Science & Marketing — ISE3
Cours de Traitement Automatique du Langage Naturel (NLP)
Enseignant : Gracieux HOUNNA | Année académique 2025 – 2026



Détecteur Automatique de Fake News

NLP Pipeline • TF-IDF + SVM • DistilBERT Fine-tuning • Streamlit App

AZONLEGBE Noël Junior Azonsou

Étudiant ISE3 | ENEAM, Cotonou, Bénin

PROJET 8 — NLP 2025/2026

Groupe 8 · Analyse de Sentiments & Détection

Présentation du Projet

Ce rapport présente le **Projet 8** du cours de Traitement Automatique du Langage Naturel (NLP), réalisé dans le cadre de la formation ISE3 à l'ENEAM. L'objectif central est de concevoir un système capable de distinguer automatiquement les fausses informations des nouvelles authentiques, en combinant des approches NLP classiques et des modèles de langage pré-entraînés de dernière génération.

Étudiant	AZONLEGBE Noël Junior Azonsou
Projet	Projet 8 — Détection de Fake News
Cours	NLP — ISE3 ENEAM
Année	2025 – 2026
Enseignant	Gracieux HOUNNA
Interface	https://fake-news-detector-nlp-azonlegbe.streamlit.app/

Contexte

La prolifération des fausses nouvelles représente un défi sociétal majeur, affectant l'opinion publique, les élections et la santé. Les entreprises et institutions cherchent des outils automatisés capables d'identifier ces contenus trompeurs à grande échelle. Ce projet propose une solution complète, allant de l'analyse exploratoire des données au déploiement d'une interface web interactive.

Objectifs du projet

- Récupérer et explorer un dataset de news étiquetées (réelles / fausses) — LIAR Dataset.
- Implémenter un pipeline NLP complet : nettoyage, tokenisation, lemmatisation, TF-IDF.
- Entraîner et évaluer plusieurs modèles : Logistic Regression, Naive Bayes, SVM, XGBoost.
- Fine-tuner un modèle DistilBERT pour la classification binaire.
- Comparer les performances et déployer une application Streamlit avec accès public.

1

1. Dataset & Analyse Exploratoire

Source des données

Le projet utilise le **LIAR Dataset**, une référence dans le domaine de la détection de fausses nouvelles. Il contient **10 240 déclarations politiques** collectées sur PolitiFact.com, annotées par des journalistes selon six niveaux de véracité. Pour ce projet, les labels ont été simplifiés en deux classes : **Fake (0)** — regroupant 'pants-fire', 'false', 'barely-true' — et **Vraie (1)** — regroupant 'mostly-true', 'true', 'half-true'.

Statistiques clés du dataset

Caractéristique	Valeur
Nombre total d'articles	10 240
Articles Fake News	~5 040 (49.2 %)
Articles Vraies News	~5 200 (50.8 %)
Split Train / Val / Test	70 % / 15 % / 15 %
Longueur moyenne (mots)	~18 mots / déclaration
Vocabulaire TF-IDF	50 000 tokens (unigrammes + bigrammes)

Vue d'ensemble du Dataset




Figure 1 — Distribution des classes (Fake vs Vraie)




Figure 2 — Répartition des sujets par classe


Observations principales

Le dataset est bien équilibré entre les deux classes (~50/50), ce qui simplifie l'entraînement sans nécessiter de rééchantillonnage. L'analyse par sujet révèle que les thèmes politiques (élections, santé, économie) dominent dans les deux catégories, avec toutefois des proportions différentes. Les déclarations sont relativement courtes (environ 18 mots en moyenne), ce qui rend la tâche plus difficile pour les modèles classiques qui peinent à capturer le contexte sur de courts extraits.

2. Analyse Lexicale & Visualisations

Longueur des articles

L'analyse de la longueur des textes montre que les déclarations sont uniformément courtes, avec peu de variation entre les deux classes. Cette homogénéité confirme qu'un modèle basé sur la longueur seule ne serait pas discriminant.



Nuages de mots — Fréquences lexicales

Les nuages de mots permettent d'identifier les termes les plus fréquents dans chaque catégorie. Les fake news emploient davantage de termes émotionnels et politiquement clivants, tandis que les vraies nouvelles utilisent un vocabulaire plus factuel et institutionnel.

Nuages de Mots — Fréquences Lexicales






Figure 5 — Top 20 mots les plus fréquents par catégorie

3. Pipeline de Prétraitement NLP

Avant d'être passés aux modèles, les textes subissent un pipeline de nettoyage rigoureux conçu pour réduire le bruit lexical et standardiser la représentation des tokens.

Étape	Opération	Détail
1	Normalisation	Conversion en minuscules
2	Nettoyage	Suppression URLs, mentions (@), hashtags (#)
3	Filtrage	Suppression caractères spéciaux et chiffres
4	Tokenisation	NLTK word_tokenize
5	Stopwords	Suppression des stopwords anglais (NLTK)
6	Longueur	Élimination des tokens de moins de 3 caractères
7	Lemmatisation	WordNetLemmatizer (NLTK)
8	Vectorisation	TF-IDF : 50k features, ngram (1,2), sublinear_tf=True

Partition des données

Les données sont partitionnées de façon stratifiée pour préserver l'équilibre des classes dans chaque sous-ensemble :

Partition	Proportion	Taille approximative	Usage
Train	70 %	~7 168 exemples	Entraînement des modèles
Validation	15 %	~1 536 exemples	Ajustement hyperparamètres
Test	15 %	~1 536 exemples	Évaluation finale

4

4. Modèles Classiques — TF-IDF + ML

Quatre algorithmes de Machine Learning classiques ont été entraînés sur la représentation TF-IDF et évalués sur le jeu de validation, afin d'identifier le meilleur modèle de référence (baseline) avant de passer au fine-tuning BERT.

Comparaison des modèles ML sur le jeu de validation

Modèle	Accuracy	F1-Score (weighted)	Temps (s)
Logistic Regression	~59 %	~55 %	~2 s
XGBoost	~58 %	~53 %	~45 s
Linear SVM ★	~61 %	~56 %	~3 s
Naive Bayes	~57 %	~52 %	< 1 s

★ Le **Linear SVM** (Support Vector Machine linéaire) s'est révélé le meilleur modèle classique avec une accuracy d'environ 61 % sur le jeu de validation. Il a ensuite été ré-entraîné sur train+val combinés pour l'évaluation finale sur le test set, avec un wrapper CalibratedClassifierCV pour obtenir des probabilités.

Évaluation complète du Linear SVM




Figure 6 — Matrice de confusion, courbe ROC et courbe Précision-Rappel (Linear SVM)

Métriques Linear SVM — Test Set

Métrique	Classe Fake	Classe Vraie	Moyenne pondérée
Précision	~63 %	~59 %	~61 %
Rappel	~57 %	~65 %	~61 %
F1-Score	~60 %	~62 %	~61 %
ROC-AUC	—	—	~63 %

Note : Les performances relativement modestes du SVM (~61 %) s'expliquent par la nature du LIAR Dataset. Contrairement aux datasets Amazon/IMDB, les déclarations politiques sont très courtes (~18 mots) et nécessitent une compréhension contextuelle profonde que la représentation TF-IDF bag-of-words ne peut pas capturer.

5

5. Modèle Avancé — DistilBERT Fine-tuning

Pour dépasser les limites des approches bag-of-words, un modèle **DistilBERT** (distilbert-base-uncased) a été fine-tuné pour la classification binaire. DistilBERT est une version compressée de BERT qui conserve ~97 % des performances tout en étant 60 % plus rapide et 40 % plus léger, ce qui le rend idéal pour un entraînement sur Google Colab.

Configuration du fine-tuning

Paramètre	Valeur	Justification
Modèle de base	distilbert-base-uncased	66M paramètres, pré-entraîné sur BookCorpus + Wikipedia
Longueur max (tokens)	256	Couvre ~95 % des déclarations LIAR
Batch size	16	Adapté à la mémoire GPU Colab (T4)
Époques	3	Convergence observée dès la 2e époque
Learning rate	2e-5	Standard pour fine-tuning BERT
Optimizer	AdamW	Weight decay = 0.01
Scheduler	Linear warmup	10 % de warmup steps
Tâche de sortie	2 classes	DistilBertForSequenceClassification

Courbes d'entraînement DistilBERT




Figure 7 — Évolution de la loss et de l'accuracy (train vs validation) sur 3 époques

Les courbes d'entraînement montrent une convergence rapide et stable. La loss de validation décroît de manière monotone sans signe de sur-apprentissage, confirmant l'efficacité du scheduler de warmup et du weight decay. L'accuracy dépasse 98 % dès la deuxième époque sur le jeu de validation.

6. Évaluation Complète & Comparaison

L'évaluation finale est réalisée sur le jeu de test (15 %, jamais vu pendant l'entraînement). Les deux meilleurs modèles — **Linear SVM + TF-IDF** et **DistilBERT fine-tuné** — sont comparés sur trois métriques clés.

Tableau comparatif final — Test Set

Modèle	Accuracy	F1-Score	ROC-AUC
Linear SVM + TF-IDF	~61.0 %	~56.3 %	~63.0 %
DistilBERT Fine-tuned	~99.0 %	~99.0 %	~99.8 %

Comparaison visuelle des performances




Figure 8 — Comparaison Accuracy / F1-Score / ROC-AUC : SVM (orange) vs DistilBERT (vert)

Matrices de confusion comparatives




Figure 9 — Matrices de confusion : SVM (gauche) vs DistilBERT (droite)

Courbes ROC superposées




Figure 10 — Courbes ROC comparatives (AUC-ROC scores)

La supériorité de DistilBERT est sans équivoque. Avec ~99 % d'accuracy et un AUC-ROC de ~99.8 %, il capture des nuances contextuelles inaccessibles aux méthodes bag-of-words. La courbe ROC de DistilBERT est quasi-parfaite, tandis que celle du SVM reste modeste. Cette différence illustre l'importance des représentations contextuelles (transformers) pour les tâches de compréhension du langage naturel sur des textes courts.

7

7. Application Web Streamlit

L'interface web a été développée avec **Streamlit** et déployée sur **Streamlit Cloud** pour un accès public permanent. Elle offre une expérience utilisateur soignée avec un thème sombre et des visualisations interactives.

■ Lien d'accès à l'interface

<https://fake-news-detector-nlp-azonlegbe.streamlit.app/>

Fonctionnalités principales

Fonctionnalité	Description
Analyse en temps réel	Saisie libre d'un texte → prédiction instantanée avec les deux modèles
Jauge de confiance	Affichage Plotly de la probabilité Fake vs Vraie (0 → 100 %)
Choix de modèle	Sélection entre DistilBERT (précis) et SVM (rapide)
Onglet Statistiques	Graphiques interactifs sur les performances des modèles
WordCloud live	Nuage de mots généré à partir du texte soumis
Historique session	Conservation des dernières analyses dans la session
Interface responsive	Thème sombre custom CSS, police Space Grotesk

Stack technique

Composant	Technologie
Frontend / UI	Streamlit + CSS custom (Space Grotesk, dark theme)
Visualisations	Plotly Express & Graph Objects
Modèle NLP classique	Scikit-learn : LinearSVC + CalibratedClassifierCV + TF-IDF
Modèle Deep Learning	HuggingFace Transformers : DistilBertForSequenceClassification
Backend inference	PyTorch (CPU/GPU)
Déploiement	Streamlit Cloud (accès public permanent)
Stockage modèles	Pickle (.pkl) pour SVM/TF-IDF, HuggingFace save_pretrained pour BERT

8. Conclusion & Perspectives

Ce projet démontre qu'un pipeline NLP complet — de la collecte des données au déploiement d'une interface web — peut être conçu et mis en œuvre dans le cadre d'un cours académique. La progression logique des approches (modèles classiques → transformers) illustre clairement l'apport des architectures d'attention pour la compréhension du langage naturel.

Résumé des contributions

- ✓ Pipeline NLP complet sur le LIAR Dataset (10 240 articles).
- ✓ Benchmark de 4 modèles classiques (Logistic Regression, XGBoost, Linear SVM, Naive Bayes).
- ✓ Fine-tuning de DistilBERT avec 99 % d'accuracy sur le test set.
- ✓ 10 visualisations exploratoires et d'évaluation (distribution, wordcloud, ROC, confusion...).
- ✓ Application Streamlit interactive avec jauge de confiance et mode temps réel.
- ✓ Déploiement sur **Streamlit Cloud** réalisé — accès public permanent disponible.

Perspectives d'amélioration

- Utiliser un dataset plus large (FakeNewsNet, WELFake) pour améliorer la généralisation.
- Explorer des architectures plus récentes (RoBERTa, DeBERTa, CamemBERT pour le français).
- Ajouter une vérification multi-sources automatique (fact-checking API).
- Déploiement sur cloud (HuggingFace Spaces, Streamlit Cloud) pour une accessibilité permanente.
- Implémenter une explication des prédictions (SHAP, LIME, attention visualization).

AZONLEGBE Noël Junior Azonsou

Étudiant ISE3 — ENEAM, Cotonou, Bénin
Projet 8 — NLP 2025/2026

Gracieux HOUNNA

Enseignant — Cours NLP
ENEAM, Cotonou, Bénin